

Caso Conteo de Palabras

Autor

Martín Vladimir Alonso Sierra Galvis

Gestión de Datos, Maestría en Ciencia de Datos
Pontificia Universidad Javeriana Cali

Versión 2.0
Santiago de Cali, marzo de 2023

Tabla de contenido

Contexto	3
Caso	4
Alcance	4

Contexto

Desde hace varios siglos, uno de los principales métodos de comunicación de los seres humanos ha sido el texto escrito. Historias y conocimiento acumulados a lo largo del tiempo han sido transmitidos de generación en generación por medio de diarios informativos, revistas o libros.

Con el advenimiento de la era digital, el texto escrito ha tomado una mayor relevancia. Diariamente son miles de personas las que expresan sentimientos o posiciones políticas por medio de estados de Facebook o trinos de Twitter. Es a raíz de estas interacciones masivas, que ocurren en las aplicaciones, que las grandes empresas, dueñas de las mismas, se han dado cuenta de la importancia de los textos compartidos. Estos se convierten, prácticamente, en una mina de información que los empresarios pueden aprovechar para distintos objetivos como analizar tendencias y sentimientos o verificar los gustos de los usuarios con fines publicitarios.

Por su parte, en el área investigativa, el conocimiento y los datos están diseminados en forma escrita a través de artículos científicos y reportes técnicos. A su vez, la información también está diseminada de forma verbal a través de interacciones científicas en conferencias, seminarios y consultas [Friedman & Jhonson], por lo que se vuelve indispensable el uso de un método con el que los investigadores logren encontrar información valiosa en esta multitud de fuentes de datos que se pueden encontrar a lo largo y ancho de la red.

En ese sentido, el Procesamiento del Lenguaje Natural, NLP por sus siglas en inglés, aparece en escena como un área de las ciencias de la computación que busca la obtención de información a partir de textos escritos e incluso lenguaje hablado, y donde el Machine Learning y la Lingüística Computacional son ampliamente usados [Vrah Shaj]. Uno de los tantos objetivos del NLP es la extracción de significado a partir de grandes volúmenes de texto: gramáticas formales que especifican relaciones entre unidades y partes del habla como sustantivos, verbos o adjetivos [Chapman]. Para lograr esto, NLP hace uso, internamente, de la técnica conocida como Procesamiento de Texto, una de las formas de procesamiento distribuido de datos.

Con el procesamiento de texto se busca realizar tareas como **tokenización**, conteo de palabras y generación, manipulación y análisis de textos. Algunos

de los usos más frecuentes del procesamiento de textos son el análisis de temáticas donde se busca categorizar colecciones grandes de textos en temas; el análisis de sentimientos donde la meta principal es detectar tonos emocionales de un texto de forma que se pueda clasificar como positivo, negativo o neutro; y la detección de intención donde el objetivo es detectar la intención de un texto, por ejemplo si determinado texto busca obtener información o realizar una compra o una venta.

Caso

Partiendo de lo planteado previamente, imaginen que un profesional está realizando una investigación sobre determinado tema de su interés y quiere saber cuántas veces aparecen determinadas palabras en una publicación de carácter científico que piensa utilizar a modo de referencia bibliográfica en su propio trabajo investigativo. Teniendo en cuenta que el artículo puede llegar a tener entre 15 y 20 páginas, sería complicado para el investigador contar por sí mismo las palabras, por lo que desea usar una herramienta que le permita procesar el texto y realizar el conteo en un menor tiempo.

Alcance

Para resolver el caso deben tener en cuenta las herramientas que estudiamos en esta unidad. Recuerden que cada herramienta, Hadoop o Spark, utiliza un Modelo de Procesamiento Distribuido distinto y goza de ciertas características, por lo que deben analizar cómo realizar el conteo de palabras y seleccionar la herramienta que mejor se ajuste al caso propuesto. Adicionalmente, considerar lo siguiente:

1. Buscar un artículo científico de su interés de entre 10 a 20 páginas. El texto de este artículo es el que usarán junto a Hadoop o Spark para realizar el conteo de palabras.
2. El conteo de palabras se debe realizar sobre la **totalidad** del texto que compone el artículo.
3. El artículo debe estar en idioma español pues la idea es hacer comparaciones para dicho idioma.
4. El resultado del conteo de palabras debe tener una estructura similar a la que se presenta a continuación:

sigamos, 1

aprendiendo, 7
sobre, 4
la, 20
gestión, 5
de, 15
datos, 5