

Informe: Instalación y Configuración de Hadoop en WSL

Estudiante: Edwin Silva Salas

Programa: Maestría en Ciencia de Datos

Universidad: Pontificia Universidad Javeriana

Grupo: C

Taller: Caso Conteo de Palabras

Fecha: 10 de Diciembre de 2025

Tabla de Contenido

1. [Introducción](#)
 2. [Instalación de Ubuntu en WSL](#)
 3. [Actualización del Sistema](#)
 4. [Instalación de Java](#)
 5. [Configuración de SSH](#)
 6. [Creación de Directorios](#)
 7. [Descarga e Instalación de Hadoop](#)
 8. [Configuración de Variables de Entorno](#)
 9. [Configuración de Archivos de Hadoop](#)
 10. [Formateo de HDFS](#)
 11. [Inicio de Servicios](#)
 12. [Verificación de la Instalación](#)
 13. [Instalación de mrjob](#)
 14. [Conclusiones](#)
-

1. Introducción

Este documento detalla el proceso completo de instalación y configuración de Apache Hadoop 3.3.6 en un entorno Windows mediante el Subsistema de Windows para Linux (WSL) con Ubuntu 22.04 LTS. El objetivo es preparar el ambiente para ejecutar tareas de procesamiento distribuido de datos, específicamente para el taller de Conteo de Palabras utilizando MapReduce.

2. Instalación de Ubuntu en WSL

2.1 Descarga de Ubuntu

Como la instalación desde Microsoft Store presentó problemas, se descargó Ubuntu manualmente:

```
# Descargar Ubuntu 22.04 desde PowerShell
Invoke-WebRequest -Uri https://aka.ms/wslubuntu2204 -OutFile Ubuntu2204-221101.AppxBundle -UseBasicParsing
```

2.2 Instalación del paquete

```
# Instalar el paquete descargado
Add-AppxPackage C:\Users\ESILVAS\Downloads\Ubuntu2204-221101.AppxBundle
```

2.3 Configuración inicial de Ubuntu

Al abrir Ubuntu por primera vez desde el menú de inicio, se solicitó:

- **Usuario:** esilvas
- **Contraseña:** [configurada por el usuario]

Salida del sistema:

```
Installing, this may take a few minutes...
Please create a default UNIX user account.
Enter new UNIX username: esilvas
New password:
Retype new password:
passwd: password updated successfully
Installation successful!
```

3. Actualización del Sistema

3.1 Actualizar repositorios

```
sudo apt update
```

Resultado: Se actualizaron 202 paquetes disponibles.

3.2 Actualizar paquetes instalados

```
sudo apt upgrade -y
```

Observación: Este comando instaló actualizaciones de seguridad y mejoras del sistema.

4. Instalación de Java

Hadoop requiere Java Development Kit (JDK) para funcionar.

4.1 Instalación de OpenJDK 11

```
sudo apt install default-jdk -y
```

Paquetes instalados:

- openjdk-11-jdk
- openjdk-11-jre
- Dependencias relacionadas (45 paquetes en total, 287 MB)

4.2 Verificación de Java

```
java -version
```

Salida esperada:

```
openjdk version "11.0.x" 2023-xx-xx  
OpenJDK Runtime Environment (build 11.0.x+x-Ubuntu-xxx)  
OpenJDK 64-Bit Server VM (build 11.0.x+x-Ubuntu-xxx, mixed mode, sharing)
```

5. Configuración de SSH

Hadoop utiliza SSH para comunicarse entre nodos. En modo pseudo-distribuido, necesita conectarse a localhost.

5.1 Instalación de SSH

```
sudo apt install openssh-server openssh-client -y
```

5.2 Inicio del servicio SSH

```
sudo service ssh start
```

5.3 Configuración de SSH sin contraseña

Generar clave SSH:

```
ssh-keygen -t rsa -P '' -f ~/.ssh/id_rsa
```

Explicación de parámetros:

- `-t rsa`: Tipo de cifrado RSA
- `-P ''`: Sin contraseña (passphrase vacía)
- `-f ~/.ssh/id_rsa`: Ubicación de la clave

Agregar clave pública a `authorized_keys`:

```
cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
```

Establecer permisos correctos:

```
chmod 0600 ~/.ssh/authorized_keys
```

Nota: SSH requiere permisos 0600 por seguridad. Permisos más abiertos causan que SSH rechace la autenticación.

5.4 Verificación de SSH

```
ssh localhost
```

Primera conexión:

```
The authenticity of host 'localhost (127.0.0.1)' can't be established.  
ED25519 key fingerprint is SHA256:703PBW5Cqk0Vn9f592Bvzd9sSylv70LhaqNjVxIf1JE.  
Are you sure you want to continue connecting (yes/no/[fingerprint])? yes
```

Se ingresó `yes` y la conexión fue exitosa sin solicitar contraseña.

Salir de la sesión SSH:

```
exit
```

6. Creación de Directorios

6.1 Directorios de trabajo

```
mkdir ~/Documents  
mkdir ~/Downloads
```

6.2 Directorios para HDFS

Estos directorios almacenarán los datos y metadatos de HDFS:

```
mkdir -p ~/hdfs/datanode  
mkdir -p ~/hdfs/namenode
```

Explicación:

- **namenode:** Almacena metadatos del sistema de archivos
- **datanode:** Almacena los bloques de datos reales

Verificar la creación:

```
ls -l ~/hdfs/
```

7. Descarga e Instalación de Hadoop

7.1 Instalación de wget

```
sudo apt install wget -y
```

7.2 Descarga de Hadoop

```
cd ~/Downloads  
wget https://dlcdn.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz
```

Resultado:

- Archivo: hadoop-3.3.6.tar.gz
- Tamaño: 696.28 MB
- Tiempo: 64 segundos (10.9 MB/s)

7.3 Extracción del archivo

```
tar -xzf hadoop-3.3.6.tar.gz
```

Parámetros del comando:

- **-x:** Extraer
- **-z:** Descomprimir gzip

- `-f`: Especificar archivo

7.4 Mover Hadoop a ubicación final

```
sudo mv hadoop-3.3.6 /usr/local/hadoop
```

Justificación: `/usr/local/` es la ubicación estándar para software instalado manualmente en sistemas Linux.

7.5 Cambiar propietario

```
sudo chown -R esilvas:esilvas /usr/local/hadoop
```

Beneficio: Permite modificar configuraciones sin necesidad de `sudo`.

7.6 Verificación

```
ls /usr/local/hadoop
```

Directorios principales:

- `bin/`: Ejecutables de Hadoop
- `etc/`: Archivos de configuración
- `sbin/`: Scripts de administración
- `share/`: Librerías y JAR files

8. Configuración de Variables de Entorno

8.1 Editar archivo `.bashrc`

```
nano ~/.bashrc
```

8.2 Agregar variables al final del archivo

```
# Hadoop y Java
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_HOME=/usr/local/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
```

```
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
```

Explicación de variables:

- **JAVA_HOME**: Ubicación de Java
- **HADOOP_HOME**: Directorio base de Hadoop
- **HADOOP_*_HOME**: Variables para componentes específicos
- **PATH**: Agrega comandos de Hadoop al sistema
- **HADOOP_OPTS**: Opciones de Java para librerías nativas

Guardar: Ctrl + O, Enter, Ctrl + X

8.3 Aplicar cambios

```
source ~/.bashrc
```

8.4 Verificación

```
echo $HADOOP_HOME
echo $JAVA_HOME
hadoop version
```

Salida esperada:

```
/usr/local/hadoop
/usr/lib/jvm/java-11-openjdk-amd64
Hadoop 3.3.6
```

9. Configuración de Archivos de Hadoop

Todos los archivos de configuración se encuentran en: **\$HADOOP_HOME/etc/hadoop/**

9.1 hadoop-env.sh

Editar:

```
nano $HADOOP_HOME/etc/hadoop/hadoop-env.sh
```

Configurar JAVA_HOME y SSH:

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_SSH_OPTS="-p 22"
```

Explicación:

- Define la ubicación de Java para Hadoop
 - Especifica el puerto SSH (22 es el estándar)
-

9.2 core-site.xml

Editar:

```
nano $HADOOP_HOME/etc/hadoop/core-site.xml
```

Configuración:

```
<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://0.0.0.0:9000</value>
  </property>
</configuration>
```

Explicación:

- `fs.defaultFS`: Define el sistema de archivos por defecto (HDFS)
 - `hdfs://0.0.0.0:9000`: HDFS escucha en todas las interfaces, puerto 9000
-

9.3 hdfs-site.xml

Editar:

```
nano $HADOOP_HOME/etc/hadoop/hdfs-site.xml
```

Configuración:

```
<configuration>
  <property>
    <name>dfs.replication</name>
    <value>1</value>
  </property>
</configuration>
```



```
<name>dfs.namenode.name.dir</name>
<value>file:///home/esilvas/hdfs/namenode</value>
</property>
<property>
  <name>dfs.datanode.data.dir</name>
  <value>file:///home/esilvas/hdfs/datanode</value>
</property>
</configuration>
```

Explicación:

- `dfs.replication`: 1 réplica (modo pseudo-distribuido)
- `dfs.namenode.name.dir`: Ubicación de metadatos
- `dfs.datanode.data.dir`: Ubicación de datos

9.4 mapred-site.xml

Editar:

```
nano $HADOOP_HOME/etc/hadoop/mapred-site.xml
```

Configuración:

```
<configuration>
  <property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
  </property>
  <property>
    <name>yarn.app.mapreduce.am.env</name>
    <value>HADOOP_MAPRED_HOME=/usr/local/hadoop</value>
  </property>
  <property>
    <name>mapreduce.map.env</name>
    <value>HADOOP_MAPRED_HOME=/usr/local/hadoop</value>
  </property>
  <property>
    <name>mapreduce.reduce.env</name>
    <value>HADOOP_MAPRED_HOME=/usr/local/hadoop</value>
  </property>
</configuration>
```

Explicación:

- `mapreduce.framework.name`: Usa YARN como gestor de recursos
- Variables de entorno para ApplicationMaster, Map y Reduce tasks

9.5 yarn-site.xml

Editar:

```
nano $HADOOP_HOME/etc/hadoop/yarn-site.xml
```

Configuración:

```
<configuration>
  <property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  </property>
</configuration>
```

Explicación:

- Habilita el servicio de shuffle necesario para MapReduce

10. Formateo de HDFS

Antes de usar HDFS por primera vez, es necesario formatearlo.

10.1 Formatear NameNode

```
hdfs namenode -format
```

Salida exitosa:

```
2025-12-10 18:15:27,866 INFO common.Storage: Storage directory
/home/esilvas/hdfs/namenode has been successfully formatted.
```

⚠ ADVERTENCIA: Este comando solo debe ejecutarse UNA VEZ. Ejecutarlo nuevamente borrará todos los datos de HDFS.

11. Inicio de Servicios

11.1 Iniciar HDFS

```
start-dfs.sh
```

Proceso:

```
Starting namenodes on [0.0.0.0]
Starting datanodes
Starting secondary namenodes [ESILVAS02]
```

Nota: Durante el primer inicio, SSH solicita confirmación para agregar hosts a `known_hosts`. Se respondió `yes` en ambas ocasiones.

11.2 Iniciar YARN

```
start-yarn.sh
```

Proceso:

```
Starting resourcemanager
Starting nodemanagers
```

12. Verificación de la Instalación

12.1 Verificar procesos Java

```
jps
```

Salida esperada:

```
12345 NameNode
12456 DataNode
12567 SecondaryNameNode
12678 ResourceManager
12789 NodeManager
12890 Jps
```

Descripción de procesos:

- **NameNode:** Gestiona metadatos de HDFS
- **DataNode:** Almacena bloques de datos
- **SecondaryNameNode:** Realiza checkpoints del NameNode
- **ResourceManager:** Gestiona recursos de YARN
- **NodeManager:** Ejecuta contenedores y tareas

- **Jps:** Comando de verificación (Java Process Status)

12.2 Interfaces Web

HDFS NameNode:

- URL: http://localhost:9870
- Información: Estado del cluster, nodos, capacidad de almacenamiento

YARN ResourceManager:

- URL: http://localhost:8088
- Información: Aplicaciones en ejecución, recursos disponibles

12.3 Comandos básicos de HDFS

Listar directorio raíz:

```
hdfs dfs -ls /
```

Crear directorio:

```
hdfs dfs -mkdir /usuario
```

Subir archivo:

```
hdfs dfs -put archivo.txt /
```

Ver contenido:

```
hdfs dfs -cat /archivo.txt
```

Descargar archivo:

```
hdfs dfs -get /archivo.txt .
```

13. Instalación de mrjob

mrjob es una librería de Python que facilita la escritura de trabajos MapReduce.

13.1 Instalar pip

```
sudo apt install python3-pip -y
```

13.2 Verificar Python

```
python3 --version
```

13.3 Instalar mrjob

```
pip3 install mrjob
```

13.4 Verificar instalación

```
python3 -c "import mrjob; print(mrjob.__version__)"
```

14. Conclusiones

Se completó exitosamente la instalación y configuración de Apache Hadoop 3.3.6 en un entorno WSL con Ubuntu 22.04 LTS. El sistema está configurado en modo pseudo-distribuido y todos los servicios principales están operativos:

- ☒ **NameNode:** Gestión de metadatos HDFS
- ☒ **DataNode:** Almacenamiento de datos
- ☒ **ResourceManager:** Gestión de recursos YARN
- ☒ **NodeManager:** Ejecución de tareas
- ☒ **SecondaryNameNode:** Backup de metadatos

El ambiente está listo para ejecutar trabajos MapReduce utilizando tanto la API nativa de Hadoop como la librería mrjob de Python.

Comandos útiles para gestión:

Detener servicios:

```
stop-dfs.sh  
stop-yarn.sh
```

Reiniciar servicios:

```
start-dfs.sh  
start-yarn.sh
```

Ver logs:

```
cat $HADOOP_HOME/logs/*.log
```

Referencias

- Apache Hadoop Documentation: <https://hadoop.apache.org/docs/r3.3.6/>
- Hadoop HDFS Architecture: <https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html>
- YARN Architecture: <https://hadoop.apache.org/docs/stable/hadoop-yarn/hadoop-yarn-site/YARN.html>
- mrjob Documentation: <https://mrjob.readthedocs.io/>

Fin del documento