

Instalación de Herramientas

Autor

Martín Vladimir Alonso Sierra Galvis

Gestión de Datos, Maestría en Ciencia de Datos
Pontificia Universidad Javeriana Cali

Versión 1.0

Santiago de Cali, marzo de 2023

Tabla de contenido

Consideraciones	2
Apache Hadoop	3
¿Qué es Apache Hadoop?	3
Instalando Apache Hadoop en WSL	3
Habilitar WSL en Windows	4
Instalar Ubuntu desde Microsoft Store	5
Configurar WSL versión 2	6
Preparar Ubuntu para Apache Hadoop	7
Instalar Apache Hadoop en Ubuntu	10
Configurar Apache Hadoop en Ubuntu	11
Ejecutar Apache Hadoop en Ubuntu	16
Instalar el módulo de Python mrjob	17

Consideraciones

Este documento está dirigido a todos aquellos alumnos que deseen instalar las herramientas de la presente unidad en sus dispositivos personales. Cabe resaltar que Hadoop y mrjob se encuentran instalados en las máquinas que provee la universidad para el desarrollo de las actividades de la maestría. Así mismo, es importante tener claro que Hadoop se puede instalar tanto en Windows como en Linux. **En esta guía en particular, veremos cómo instalar Hadoop en Linux, usando para ello WSL.** Esto debido a que el uso de mrjob con Hadoop directamente en el sistema operativo Windows no es estable, por lo que se pueden presentar errores. Existe una tercera forma de trabajar Hadoop: mediante Hortonworks, una imagen de máquina virtual de Cloudera. Aunque esta tercera forma tiene la ventaja de traer todo preconfigurado, no se recomienda por la demanda de recursos en el dispositivo.

Apache Hadoop

¿Qué es Apache Hadoop?

Apache Hadoop, a día de hoy, es todo un conjunto de herramientas enfocadas a trabajar con Big Data; es, en esencia, lo que podríamos denominar como un framework o un motor de procesamiento distribuido de datos. Creado y publicado por Doug Cutting y Mike Cafarella en 2006, y actualmente uno de los principales proyectos de Apache, es considerada la primera herramienta de su tipo y sobre la que trabajan muchos de los motores de procesamiento distribuido modernos, como es el caso de Spark. En esta unidad trabajaremos con Hadoop en su versión 3.3.4, la versión más actualizada de este motor. En ese sentido, existen dos maneras principales para utilizar Hadoop: instalándolo en un sistema operativo Linux, considerada la mejor y más segura; o instalándolo en un sistema operativo Windows, un poco más inestable que la anterior. En esta guía abordaremos la primera forma, utilizando para ello WSL. Así, tanto los usuarios de Linux como los de Windows tendrán la posibilidad de explorar y experimentar con Hadoop en sus dispositivos personales.

Instalando Apache Hadoop en WSL

Hadoop es una herramienta que funciona sumamente bien con el sistema operativo Linux. La cuestión es que muchos de nosotros estamos más familiarizados con Windows por ser el sistema operativo más ampliamente usado en los computadores del hogar y el trabajo. Pero, si queremos tener la certeza que Hadoop va a ejecutar sus procesos correctamente, tendremos que adentrarnos en el mundo del pingüino. En ese sentido, tenemos tres opciones para usar Linux sin tener que quitar Windows de nuestro dispositivo personal:

1. Descargar la imagen .ISO de Linux, particionar el disco duro de nuestro dispositivo y crear un **dual boot**, es decir, un arranque especial que nos permite elegir entre Windows y Linux para iniciar sesión. Este método está muy orientado para aquellos usuarios que tienen mucha experiencia usando tanto Windows como Linux.
2. Descargar la imagen .ISO de Linux, descargar una máquina virtual como Oracle VirtualBox o VMWare y ejecutar el ISO en dicha máquina

virtual. Aunque este método es más simple, también es un poco más ineficiente pues las máquinas virtuales pueden llegar a ocupar bastante espacio, especialmente, en memoria.

3. Usar el contenedor virtual **Subsistema de Windows para Linux**, o **WSL** por sus siglas en inglés. WSL es una herramienta que viene con las últimas versiones de Windows y que, como su nombre lo indica, nos permite instalar Linux como un subsistema de Windows. Este método es el más sencillo por lo que será el que vamos a utilizar, tanto para la presente guía de instalación como para el ejemplo práctico.


Habilitar WSL en Windows

Antes de habilitar WSL Windows, debemos tener la certeza que nuestro sistema operativo Windows tiene la capacidad de utilizar este software. Para ello, vamos al buscador del sistema, mismo que normalmente se encuentra en la barra de tareas, y buscamos el comando **winver**. Al ejecutarlo, nos aparecerá la siguiente ventana.



Aquí podemos ver tanto la versión del sistema como la compilación instalada. Como la idea es usar WSL2, debemos verificar que la compilación sea mayor a la 19041 (si el número de la compilación es menor, es factible usar WSL, versión 1). Una vez que realicemos esta verificación, procedemos a habilitar el software. Buscamos la aplicación **Panel de control** en el

buscador del sistema y la ejecutamos. En el Panel de control seleccionamos la opción **Programas**, seguidamente la opción **Programas y características** y, finalmente, en el menú izquierdo, **Activar o desactivar las características de Windows**. Lo anterior abrirá una ventana como la que se muestra a continuación.




En este punto debemos seleccionar dos características para activar: **Plataforma de máquina virtual** y **Subsistema de Windows para Linux**. Damos click en Aceptar y Windows comenzará a descargar lo necesario para habilitar las características que acabamos de seleccionar. Cuando este proceso termine, el sistema nos pedirá que reiniciemos el dispositivo; damos en la opción Reiniciar ahora.

Instalar Ubuntu desde Microsoft Store

Después que nuestro dispositivo reinicie, estamos listos para instalar Linux en el WSL. Debemos saber que Linux cuenta con infinidad de distribuciones, cada una con sus propias características que las hacen propicias para determinadas situaciones. En nuestro caso instalaremos **Ubuntu**, una de las distribuciones Linux más conocidas, con un amplio soporte debido a su extensa comunidad. Accedemos pues a la aplicación Microsoft Store de Windows y buscamos Ubuntu en la barra de búsqueda de la aplicación. Entre los resultados buscamos y seleccionamos **Ubuntu 22.04.2 LTS** y a

continuación damos click en el botón Obtener. Esto comenzará con la descarga del sistema operativo Ubuntu versión 22.04.2 LTS, misma que puede tardar varios minutos debido a su tamaño. Siempre se recomienda instalar las versiones LTS pues son las que tienen un soporte más prolongado en el tiempo. Al terminar la descarga podremos ver que el botón Obtener ha sido reemplazado por un botón **Abrir** como se muestra en la siguiente imagen.



Damos click en dicho botón y se abrirá una ventana de línea de comandos correspondiente a una terminal de Ubuntu sobre WSL. Veremos inicialmente un mensaje que nos indica que se está instalando Ubuntu y todos sus componentes. Cuando termine la instalación, Ubuntu nos pedirá que ingresemos un nombre para nuestro usuario y una contraseña asociada a dicho usuario. ¡Ojo! Este usuario y contraseña pueden ser diferentes a los que normalmente utilizamos para ingresar a Windows. Una vez definidos estos datos, cerramos la ventana pues, antes de comenzar a trabajar con Ubuntu, haremos unas pocas configuraciones al WSL.

Configurar WSL versión 2

Cuando se trabaja con WSL es recomendable que, si tenemos la posibilidad, actualicemos la herramienta a su versión 2. Así tendremos un mejor rendimiento con este software. El cambio de versión lo podemos hacer

ejecutando una **Windows PowerShell** en modo **administrador**, misma que podemos encontrar por medio del buscador del sistema. Esta aplicación no es más que una versión avanzada del Símbolo del sistema de Windows; básicamente, una línea de comandos. Para realizar el proceso de actualización ingresamos y ejecutamos los siguientes comandos en orden (recordemos que para hacer efectiva la ejecución de un comando, debemos presionar la tecla **Enter** de nuestro teclado por cada comando que escribamos):

```
wsl --update
```

```
wsl --set-version Ubuntu-22.04 2
```

Al ejecutar el último comando, comenzará la actualización, proceso que puede tardar varios minutos como nos lo indica PowerShell. Cuando termine el proceso de actualización, podemos verificar la versión de WSL con el comando:

```
wsl -l -v
```

Lo que mostrará el siguiente resultado en la línea de comandos:

NAME	STATE	VERSION
* Ubuntu-22.04	Running	2


Finalmente, y con el propósito de configurar la versión 2 como versión por defecto para posibles instalaciones futuras con WSL, ejecutamos el siguiente comando:

```
wsl --set-default-version 2
```

Con esto hemos terminado la configuración de WSL2 y podemos comenzar a trabajar en el sistema operativo Ubuntu 22.04.2 LTS.

Preparar Ubuntu para Apache Hadoop

Lo primero es ejecutar nuevamente Ubuntu, acción que podemos llevar a cabo buscando la aplicación Ubuntu 22.04.2 LTS en el buscador del sistema. Esto nos abrirá la siguiente ventana, donde podremos observar otra línea de comandos.



Cabe resaltar que lo que estamos observando es, básicamente, el sistema operativo Ubuntu Linux, ejecutándose como un subsistema de Windows. La pregunta que nos podría surgir aquí es: ¿esta línea de comandos es todo un sistema operativo Linux? La respuesta es sí, y la razón por la que solamente vemos una línea de comandos es porque la versión que instalamos es la versión base, misma que no cuenta con una interfaz gráfica. Pero, para trabajar con Hadoop, la línea de comandos es suficiente. En este punto, debemos preparar Ubuntu para trabajar con Hadoop. Lo primero es actualizar el sistema operativo con el siguiente comando:

```
sudo apt update && apt upgrade -y
```

Al ser la actualización de todo el sistema operativo Ubuntu, el proceso puede tardar varios minutos. Una vez el proceso de actualización se complete, procedemos a instalar **Java**. Esto porque Hadoop es una herramienta construida utilizando este lenguaje de programación por lo que necesita del JDK, el JRE y la Java Virtual Machine **JVM** para ejecutar sus procesos de manera exitosa. Instalamos la última versión de Java mediante el siguiente comando:

```
sudo apt install default-jdk
```

Al ejecutar el comando, se instalará Java 11; este proceso también puede tardar varios minutos pues la cantidad de archivos que se descargan e instalan es bastante grande. Cuando este proceso llega a su fin, es momento de instalar un servidor y un cliente especiales que nos permita utilizar el puerto 22 para realizar conexiones por **ssh**. Ejecutamos entonces los siguientes comandos para obtener el servidor y el cliente, y para iniciar el servicio ssh.

```
sudo apt install openssh-server openssh-client -y  
sudo service ssh start
```

Seguidamente, lo que haremos será crear dos directorios que usaremos brevemente al momento de instalar y trabajar con Hadoop: **Documents** y **Downloads**. Los comandos que nos ayudarán a crear estos directorios son:

```
sudo mkdir /home/[usuario]/Documents  
sudo mkdir /home/[usuario]/Downloads
```

La expresión **[usuario]** debemos cambiarla por el nombre de usuario que especificamos al momento de instalar Ubuntu 22.04.2 LTS. Por último, y como configuración opcional, podemos agregar algo de seguridad al momento de realizar conexiones por medio de ssh usando el comando **ssh-keygen -t rsa** y dando Enter a todas las opciones que nos vaya presentando la terminal. Esto generará una **clave ssh** que se ubicará en el directorio oculto **.ssh/**. Para autorizar la clave, la copiaremos desde su archivo original **id_rsa.pub** a **authorized_keys** y daremos los permisos necesarios al nuevo archivo ejecutando los siguientes comandos:

```
sudo cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys  
sudo chmod 640 ~/.ssh/authorized_keys
```

Podemos probar este paso opcional agregando **localhost** a la lista de hosts conocidos que pueden utilizar la clave ssh para conectarse por este medio. Utilizamos para la prueba el comando de conexión y registro:

```
ssh localhost
```

Si todo ha marchado bien, la terminal nos debe desplegar el siguiente mensaje de verificación:

```
The authenticity of 'localhost (127.0.0.1)' can't be
established. ECDSA key fingerprint is SHA256:[clave hash de
tipo SHA256]. Are you sure you want to continue connecting
(yes/no/[fingerprint]):
```

Simplemente ingresamos la palabra **yes** y damos Enter, agregando así localhost a la lista de hosts conocidos. Si decidimos realizar este paso de configuración, debemos tener presente que, cuando iniciemos los elementos principales del sistema de archivos de Hadoop, namenode y datanode, nos aparecerá el mismo mensaje y deberemos ingresar la misma palabra **yes**.

Instalar Apache Hadoop en Ubuntu

Como se mencionó al principio de este documento, usaremos la última versión de Hadoop, la 3.3.4. Para instalarla, debemos descargar todos los archivos binarios de la herramienta. ¿Cómo podemos realizar una descarga mediante una línea de comandos? Utilizando el comando **wget**, propio de los sistemas operativos Linux. Accedemos pues al directorio Downloads y ejecutamos los comandos correspondientes así:

```
cd Downloads/
wget
https://downloads.apache.org/hadoop/common/hadoop-3.3.4/hado
op-3.3.4.tar.gz
```

Cuando la descarga termine, y utilizando el comando **ls**, podremos ver el archivo de nombre **hadoop-3.3.4.tar.gz** en nuestra ubicación actual, en el directorio Downloads. Este es un archivo comprimido que debemos descomprimir mediante el siguiente comando:

```
tar -xvzf hadoop-3.3.4.tar.gz
```

La descompresión es otro proceso que puede tardar un tiempo, esto debido a que el número de archivos que deben descomprimirse es bastante grande. Una vez que el proceso finalice, procederemos a mover el directorio

resultante a una ubicación más propicia para su uso. Usamos para ello el siguiente comando:

```
sudo mv hadoop-3.3.4 /usr/local/hadoop
```


El anterior comando mueve todo el contenido de hadoop-3.3.4 a la ubicación /usr/local/hadoop, borrando en el proceso el directorio original. Se puede decir que con estos sencillos pasos hemos instalado Hadoop 3.3.4 en Ubuntu. Pero, para que la herramienta pueda ejecutarse de manera correcta, debemos realizar algunas configuraciones adicionales.

Configurar Apache Hadoop en Ubuntu

La primera configuración que tenemos que realizar es colocar unas variables muy específicas en el **PATH** de Linux. Esto asegurará que podamos utilizar comandos propios de Hadoop en la línea de comandos de Ubuntu, además de permitir que ciertos procesos de la herramienta, como levantar HDFS o aplicar el procesamiento MapReduce, se ejecuten correctamente. En ese sentido, modificaremos un archivo oculto del sistema llamado **bashrc**. Para ello, usamos el editor de texto integrado **nano** mediante el siguiente comando:

```
sudo nano ~/.bashrc
```

Esto abrirá el contenido del archivo bashrc. Con ayuda de las flechas del teclado, nos desplazamos hasta el final del archivo y agregamos las variables **export** que se muestran en la imagen.



```
martin@LAPTOP-NLKET56M: ~
GNU nano 6.2 /home/martin/.bashrc

# enable programmable completion features (you don't need to enable
# this, if it's already enabled in /etc/bash.bashrc and /etc/profile
# sources /etc/bash.bashrc).
if ! shopt -oq posix; then
  if [ -f /usr/share/bash-completion/bash_completion ]; then
    . /usr/share/bash-completion/bash_completion
  elif [ -f /etc/bash_completion ]; then
    . /etc/bash_completion
  fi
fi

export HADOOP_HOME=/usr/local/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"

^G Help      ^O Write Out  ^W Where Is   ^K Cut        ^T Execute    ^C Location   M-U Undo
^X Exit      ^R Read File  ^\ Replace    ^U Paste      ^J Justify    ^_ Go To Line  M-E Redo
```

Al terminar de agregar todas las variables, tecleamos **Ctrl + O**, seguido de Enter para guardar los cambios que hicimos en el archivo; lo cerramos tecleando **Ctrl + X**. Al volver a la terminal de Ubuntu, ejecutamos el siguiente comando para aplicar los cambios en el PATH del sistema:

```
source ~/.bashrc
```

La siguiente configuración es asociar la ubicación de Java en el sistema a la variable `JAVA_HOME` de Hadoop. Para saber la ubicación en la que se instaló Java 11, utilizamos el comando:

```
which javac
```

Este nos arrojará una ruta al archivo **javac** que, normalmente, es `/usr/bin/javac`. Con esta ruta al compilador de Java, podemos obtener la ubicación de Java 11, ejecutando el siguiente comando:


```
readlink -f /usr/bin/javac
```

Obteniendo como resultado la ruta en la que podemos encontrar el JDK de Java: **`/usr/lib/jvm/java-11-openjdk-amd64/bin/javac`**. De esta ruta solo nos interesa `/usr/lib/jvm/java-11-openjdk-amd64`; podemos usar nuestro mouse para seleccionar esta parte de la ruta y utilizar el botón

derecho del mismo para copiarla y pegarla en un bloc de notas de Windows pues la vamos a necesitar. Posteriormente, ingresamos y ejecutamos:

```
sudo nano /usr/local/hadoop/etc/hadoop/hadoop-env.sh
```

Lo que abrirá el archivo de ejecución **hadoop-env.sh** en el editor nano. Aquí buscamos la variable **export JAVA_HOME** y le asignamos la ruta que copiamos. Adicionalmente, una línea por debajo, agregamos la variable **export HADOOP_SSH_OPTS** con su respectivo valor, como se muestra en la siguiente imagen.



```
# The java implementation to use. By default, this environment  
# variable is REQUIRED on ALL platforms except OS X!  
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64  
export HADOOP_SSH_OPTS="-p 22"
```

Tecleamos **Ctrl + O**, seguido de Enter, y cerramos el archivo con **Ctrl + X** para volver a la línea de comandos o terminal de Ubuntu. A modo de explicación, la variable HADOOP_SSH_OPTS ayudará a conectar por el puerto 22 de ssh los datanode y el namenode de Hadoop. Esto lo podremos evidenciar cuando iniciemos estos dos elementos del sistema de archivos de la herramienta.

Ahora vamos a editar los archivos de configuración de Hadoop. Estos archivos, cuyo contenido está estructurado usando un lenguaje de etiquetas conocido como XML, son: **core-site.xml**, **hdfs-site.xml**, **mapred-site.xml** y **yarn-site.xml**. Los mismos se encuentran ubicados en la ruta /usr/local/hadoop/etc/hadoop/. Comencemos por core-site.xml; ingresamos y ejecutamos el siguiente comando para editar el archivo.

```
sudo nano /usr/local/hadoop/etc/hadoop/core-site.xml
```

Al abrirlo, podemos ver una etiqueta de nombre **<configuration>**. Dentro de esta colocaremos otras etiquetas con datos relacionados al sistema de archivos HDFS de Hadoop, tal como se muestra en la siguiente imagen.

```
<configuration>
<property>
  <name>fs.default.name</name>
  <value>hdfs://0.0.0.0:9000</value>
</property>
</configuration>
```

Así, indicamos a Hadoop que su sistema de archivos estará disponible por la ruta de conexión 0.0.0.0, puerto 9000. Guardamos con **Ctrl + O** y Enter, y cerramos con **Ctrl + X**. Pasemos ahora a editar el archivo hdfs-site.xml. Pero, antes de esto, debemos crear dos directorios que servirán para alojar los datos de los dos elementos principales del sistema de archivos de Hadoop: los datanode y el namenode. Usamos, entonces, los siguientes comandos para tal fin:

```
sudo mkdir /home/[usuario]/hdfs/datanode
sudo mkdir /home/[usuario]/hdfs/namenode
sudo chown -R [usuario]:[usuario] /home/[usuario]/hdfs
```

Con el comando **chown** nos aseguramos que el directorio /home/[usuario]/hdfs, donde creamos los subdirectorios datanode/ y namenode/, pertenezcan a nuestro usuario, definido por [usuario]. Recordemos que, como se explicó anteriormente, la expresión **[usuario]** debemos cambiarla por el usuario que creamos al instalar Ubuntu 22.04.2 LTS. Ahora sí, editemos hdfs-site.xml:

```
sudo nano /usr/local/hadoop/etc/hadoop/hdfs-site.xml
```

En la etiqueta <configuration> colocamos algunos datos adicionales que corresponden al sistema de archivos HDFS de Hadoop, mismos que podemos ver en la siguiente imagen.

```
<configuration>
<property>
  <name>dfs.replication</name>
  <value>1</value>
</property>
<property>
  <name>dfs.name.dir</name>
  <value>file:///home/martin/hdfs/namenode</value>
</property>
<property>
  <name>dfs.data.dir</name>
  <value>file:///home/martin/hdfs/datanode</value>
</property>
</configuration>
```

De esta forma le estamos diciendo dos cosas a Hadoop: la primera es que vamos a realizar una única replicación de los datos que se encuentren almacenados en el sistema de archivos de Hadoop; y la segunda es que los elementos datanode y namenode, encargados de almacenar y procesar los datos en dicho sistema de archivos, se encontrarán ubicados en los directorios que creamos antes. Una vez definimos esto, guardamos el archivo con **Ctrl + O** y Enter, y lo cerramos con **Ctrl + X**. Continuamos con la edición del siguiente archivo, mapred-site.xml:

```
sudo nano /usr/local/etc/hadoop/mapred-site.xml
```

Dentro de la etiqueta <configuration> colocaremos datos relacionados al modelo de procesamiento MapReduce, uno de los dos pilares de Hadoop junto al sistema de archivos HDFS. En la siguiente imagen podemos observar los datos que debemos colocar.

```

<configuration>
<property>
  <name>mapreduce.framework.name</name>
  <value>yarn</value>
</property>
<property>
  <name>yarn.app.mapreduce.am.env</name>
  <value>HADOOP_MAPRED_HOME=/usr/local/hadoop</value>
</property>
<property>
  <name>mapreduce.map.env</name>
  <value>HADOOP_MAPRED_HOME=/usr/local/hadoop</value>
</property>
<property>
  <name>mapreduce.reduce.env</name>
  <value>HADOOP_MAPRED_HOME=/usr/local/hadoop</value>
</property>
</configuration>

```

Básicamente, lo que estamos haciendo es señalar a Hadoop la ruta del directorio desde donde se debe aplicar el procesamiento MapReduce cuando así se requiera. Como vemos, dicha ruta corresponde en realidad al directorio `/usr/local/hadoop/`, directorio donde se encuentra la instalación de Hadoop. Guardamos usando **Ctrl + O** y Enter y cerramos con **Ctrl + X**. Finalmente, editamos el archivo `yarn-site.xml` por medio del comando:

```
sudo nano /usr/local/hadoop/etc/hadoop/yarn-site.xml
```

Al igual que sucedía con los anteriores archivos, debemos colocar los siguientes datos de configuración dentro de la etiqueta `<configuration>`.

```

<configuration>

<!-- Site specific YARN configuration properties -->
<property>
  <name>yarn.nodemanager.aux-services</name>
  <value>mapreduce_shuffle</value>
</property>
</configuration>

```

Estos datos hacen posible que Hadoop utilice el paso **shuffle** en el procesamiento MapReduce. En este punto, hemos finalizado las configuraciones necesarias para ejecutar Hadoop en Ubuntu.

Ejecutar Apache Hadoop en Ubuntu


Como primer paso para ejecutar Hadoop, tenemos que darle un formato al namenode del sistema de archivos HDFS. Esto lo podemos hacer utilizando el siguiente comando:

```
hdfs namenode -format
```

Gracias a las configuraciones que realizamos previamente, podemos utilizar con total libertad diferentes comandos de Hadoop como **hadoop**, **hdfs**, **fs**, entre otros. Si todo marcha con normalidad, nos debería salir un mensaje como "namenode has been successfully formatted", lo que nos indica que el formateo del namenode fue exitoso. Ahora, el segundo paso es iniciar el sistema de archivos HDFS y el YARN. Este último concepto hace referencia a una especie de pequeño sistema operativo que se encarga de administrar todos los procesos internos de Hadoop. Para llevar a cabo esta acción, ejecutamos los comandos:

```
start-dfs.sh  
start-yarn.sh
```

Si hemos ejecutado previamente el servidor ssh con el comando **sudo service ssh start**, el resultado de los anteriores comandos debería ser el siguiente.



```
martin@LAPTOP-NLKET56M:~$ start-dfs.sh  
Starting namenodes on [0.0.0.0]  
Starting datanodes  
Starting secondary namenodes [LAPTOP-NLKET56M]  
martin@LAPTOP-NLKET56M:~$ start-yarn.sh  
Starting resourcemanager  
Starting nodemanagers  
martin@LAPTOP-NLKET56M:~$
```

Ahora bien, para comprobar que, efectivamente, todos los servicios de Hadoop se están ejecutando correctamente podemos usar el comando `jps`, mismo que debería arrojararnos un resultado como el que se observa a continuación.

```
martin@LAPTOP-NLKET56M:~$ jps
466 NameNode
1699 Jps
1270 NodeManager
761 SecondaryNameNode
1163 ResourceManager
573 DataNode
martin@LAPTOP-NLKET56M:~$
```

Lo interesante es que podemos ver en funcionamiento los elementos principales de Hadoop como un namenode, un datanode y un datanode secundario, es decir, una réplica del datanode principal. En este punto podemos decir que Apache Hadoop se encuentra completamente funcional en el sistema operativo Ubuntu 22.04.2 LTS.

Instalar el módulo de Python mrjob

Como se mencionó durante el proceso de instalación, Apache Hadoop es una herramienta que funciona con el lenguaje de programación Java. Incluso, en su instalación base, ya cuenta con diversos archivos **.jar**, o archivos Java compilados, que son capaces de ejecutar, por ejemplo, procesamientos de tipo MapReduce. El asunto es que, en esta unidad, pretendemos entender cómo funciona MapReduce internamente y cómo podemos personalizar un procesamiento distribuido con este modelo. Y para ello usaremos el lenguaje de programación Python, lenguaje con el que, muy seguramente, estemos más familiarizados por haber trabajado con él en anteriores unidades. La buena noticia es que Ubuntu viene con Python 3.10.x preinstalado. Lo único que tendremos que hacer es instalar el módulo **mrjob** con el que implementaremos procesamientos MapReduce personalizados. Así pues, ejecutamos los siguientes comandos:

```
sudo apt install python3-pip
pip3 install mrjob
```

El primer comando instala **pip** para la versión 3.x de Python. Recordemos que pip es, básicamente, el administrador de módulos de Python, con el que podremos instalar, actualizar o desinstalar del sistema operativo los módulos que necesitamos para determinados proyectos. El segundo comando utiliza **pip3** para instalar el módulo mrjob. Si queremos verificar que la instalación de este último módulo fue exitosa podemos usar el comando **pip3 list**,

mismo que imprime una lista con los módulos de Python que se encuentran instalados en el sistema; entre ellos debería estar mrjob, versión 0.7.4.